Zadatci za vježbu i upute za NoSQL projekt
iz predmeta
Napredni modeli i baze podataka

Upute su podijeljene u dva dijela:

1 Upoznavanje s osnovnim MongoDB funkcionalnostima
2 Projekt

Sadržaj

1 Upoznavanje s osnovnim MongoDB funkcionalnostima

1.1 Instalacija

Instalirajte MongoDB: https://www.mongodb.com/download-center/community

Napomena za Windows korisnike:

- možete ga instalirati kao servis, te ga onda pokrećete u Services, te Mongo za postavke konzultira mongod.cfg datoteku iz bin direktorija. U njoj je definirana log datoteka koja će vam možda biti korisna kasnije kod pisanja MR upita jer svi ispisi putem print funkcije će biti preusmjereni u tu datoteku
- ako Mongo ne instalirate kao servis, onda ćete ga trebati ručno pokretati iz terminala. Tada će svi ispisi završiti u terminalu. Evo jedan primjer pokretanja „ručno“ iz instalacijskog direktorija:

```
D:\Program Files\MongoDB\Server\3.4> bin\mongod --vv --config "d:\Program
Files\MongoDB\Server\3.2\data\mongo.conf" --dbpath "d:\Program Files\MongoDB\Server\3.2\data\db"
```

1.2 Unos, izmjena i brisanje vrijednosti

(Otvorite drugi terminal) i pokrenite mongo *shell*:

```
mongo
```

Pokrenite naredbu koja ispisuje pomoć za rad u *shellu*:

```
help
```

Primijetite da za neke kategorije možete dobiti detaljniji opis. Iz *shella* možete izaći s CTRL+C.

Preporučuje se koristiti shell iz terminala, barem za prvi dio (kod MR naredbi je zgodno imati neki dodatni alat). Ipak, možete koristiti i alternativne GUI alate koji podržavaju shell naredbe (kako bi mogli pratiti upute), pogledajte npr.: http://mongodb-tools.com/
Shell je moguće pokretati i s vanjskog računala, pogledajte opasku u poglavlju binarne datoteke.

Pogledajte koje su raspoložive baze podataka:

```
show dbs
```

Baza podataka „local“ je interna tj. sistemska mongo baza podataka u koju mongo sprema (meta)podatke i ne treba ju dirati. Pogledajte na koju bazu podataka ste spojeni:

```
db
```

Mongo, po defaultu, spaja korisnika na bazu „test“ (zašto se nije vidjela s show dbs?).
Prebacite se na bazu podataka „nmbp“:

```
use nmbp
db
```

Osim mongo naredbi, u mongo ljusci možete obavljati i javascript kod jer je mongo shell i javascript interpreter. Isprobajte neke js izraze, npr.:

```
var d = new Date()
d
d.getF <pritisnite TAB nakon Y>   // dobiti ćete getFullYear()
var obj = { ime: 'Ana', voli: ['Milovana', 'Ivana']}
obj
```

Mongo shell se može pokrenuti i u tzv. „blind mode“, tj. može joj se zadati argument (izraz ili npr. js datoteka) koju ona onda obavlja; zgodno za npr. obavljanje zakazanih (*scheduled*) skriptiranih zadaća.

1.2.1 Unos zapisa

Zapisi su grupirani u kolekcije (*collections*) koje su donekle analogne tablicama u relacijskim bazama podataka. Za razliku od baza podataka, kolekcije se ne moraju eksplicitno stvarati, već same nastaju kada se unese prvi zapis u kolekciju.
Što se tiče samih zapisa odnosno elemenata kolekcije, jedino pravilo koje se tiče sheme podataka jest da svaki zapis mora imati **_id** atribut. Ako se taj atribut ne navede kod unosa zapisa, Mongo će ga sam generirati.
U bazi nmbp probajte naredbu kojom se ispisuju postojeće kolekcije:

```
show collections
```

Očekivano, nema niti jedne kolekcije. Unesite jedan zapis u kolekciju student:

```
db.student.save({ime:"Ana", prezime:"Kralj"})
```

Probajte ponovo:

```
show collections
```

Osim kolekcije student, nastala je i nova kolekcija `system.indexes` u kojoj se pohranjuju indeksi.
Pogledajte uneseni zapis:

```
db.student.find()
```

i primijetite generirano `_id` polje. Svojstva `_id` polja su detaljnije opisana ovdje http://docs.mongodb.org/manual/reference/object-id/ , npr. iz generiranog `_id` polja možete doznati vrijeme nastanka zapisa što često zna biti korisno:

```
ObjectId().getTimestamp("<ovdje kopirajte svoj _id>");
```

Probajte sad unijeti još dva zapisa s eksplicitno zadanim, istim `_id`-om:

```
db.student.save( {_id: 1, ime:"Eva", prezime:"Kralj"} )
db.student.find()
db.student.save( {_id: 1, ime:"Mirta", prezime:"Car"} )
db.student.find()
```

Što se dogodilo?
Probajte sad insert naredbu za unos podataka:

```
db.student.insert( {_id: 2, ime:"Maksim", prezime:"Beg"} )
db.student.find()
db.student.insert( {_id: 2, ime:"Maks", prezime:"Beg"} )
db.student.find()
```

U čemu je razlika?
Ima li smisla koristiti insert bez zadanog `_id` polja?

1.2.2 Izmjena zapisa

Probajmo izmijeniti postojeći zapis. Pretpostavimo da imamo kolekciju u kojoj nešto brojimo po danima u tjednu. Unesimo zapis za ponedjeljak:

```
db.counter.insert({_id: 'mon', cnt: 0})
db.counter.find()
```

Zatim želimo povećati brojač za jedan:

```
var mon = db.counter.findOne({_id: 'mon'});
mon
mon.cnt += 1;
db.counter.save(mon);
db.counter.find();
```

Koji je problem s ovakvim pristupom?
Mongo ima `update` naredbu koja ima svojstvo **atomarnosti** na razini dokumenta:

```
Db.collection.update(query, update, options)
```

Povećajte vrijednost brojača putem `update` naredbe. Koristi se Mongova funkcija za inkrementiranje `$inc` (popis funkcija možete pronaći ovdje https://docs.mongodb.org/manual/reference/operator/update-field/).

```
db.counter.update( {_id: 'mon'}, { $inc: {cnt:1}})
```

Zašto je ovo bolje od prethodnog pristupa?
Dodajmo dodatni atribut u naš dokument, npr. vremensku oznaku zadnje izmjene – koristi se $set funkcija:

```
db.counter.update( {_id: 'mon'}, { $set: {dateModified: null }});
db.counter.find();
```

koji ćemo postavljati kod svake operacije (npr. uvećanje za 1)

```
db.counter.update( {_id: 'mon'},
                   { $inc: {cnt:1}, $set: {dateModified: new Date()}})
```

Atribut se može ukloniti s `$unset` operatorom, odnosno preimenovati s `$rename` operatorom. Isprobajte.

Pretpostavimo da smo se predomislili i da želimo pohranjivati trenutke svakog uvećanja. Pretvorit ćemo `dateModifed` u polje i kod svakog uvećanja dodavati element u polje (mogli smo i ukloniti `dateModified` pomoću `$unset`, druga naredba bi stvorila polje):

```
db.counter.update( {_id: 'mon'}, { $set: {dateModified: [] }});
db.counter.update( {_id: 'mon'},
                   { $inc: {cnt:1}, $push: {dateModified: new Date()}})
```

Ponovite drugu naredbu više puta, te pogledajte sadržaj (`$push` je naredba analogna onoj iz Javascripta, https://developer.mozilla.org/en-US/docs/Web/JavaScript/Reference/Global_Objects/Array/push).

Napravite neku drugu kolekciju i u polje dodajte duple elemente. `$push` naredba dodaje elemente u polje bez provjere duplikata. Ako želite imati samo jedinstvene elemente u polju odnosno ako želite imati skup a ne polje, možete umjesto `$push` koristiti naredbu `$addToSet`.
Isprobajte.
Isprobajte `$pull` operator kojim se element uklanja iz skupa. Kako se ponaša kada postoji više istih elemenata?
Isprobajte $pop operator kojim se uklanja element iz polja (niza), primijetite da mu se mogu zadati i negativni argumenti (npr., 1 i -1, https://docs.mongodb.com/manual/reference/operator/update/pop/). Npr. ako hoćemo poništiti zadnje uvećanje:

```
db.counter.update( {_id: 'mon'} ,
                   { $inc: {cnt: -1},  $pop: {dateModified : 1 } } )
```

Unesimo još nekoliko zapisa:

```
db.counter.insert({_id: 'tue', cnt: 1})
db.counter.insert({_id: 'wed', cnt: 2})
db.counter.insert({_id: 'thu', cnt: 3})
db.counter.insert({_id: 'fri', cnt: 4})
db.counter.insert({_id: 'sat', cnt: 5})
db.counter.insert({_id: 'sun', cnt: 6})
db.counter.find()
```

i probajmo ih sve postaviti na početak (reset). Prazan uvjet dohvata {} će odabrati **sve** dokumente:

```
db.counter.update( { },
                   { $set: {cnt: 0, dateModified: []}})
```

Što se dogodilo? Kada je dohvatio više dokumenata, mongo po defaultu promijeni samo prvoga. To se može izmijeniti zastavicom multi:

```
db.counter.update( { },
                   { $set: {cnt: 0, dateModified: []}},
                   {multi: true})
```

Ako se hoće promijeniti točno jedan dokument, što je čest slučaj, onda je bolje koristiti naredbu `findAndModify` koju je upravo za to namijenjena.
Pogledajte dokumentaciju i isprobajte https://docs.mongodb.org/manual/reference/command/findAndModify/ .

1.2.3 Dohvat zapisa

Dohvat se obavlja pomoću `find` funkcije koja je oblika:

```
db.collection.find(query, projection)
```

pri čemu su oba argumenta opcionalna. Prvim argumentom se zadaje objekt kojim se odabiru zapisi iz baze, a drugim argumentom je moguće definirati projekciju kako se ne bi vraćali cijeli dokumenti. Funkcija vraća listu zapisa (`cursor`) po kojoj je zatim moguće iterirati. Mongo *shell* automatski iterira po listi i ispisuje prvih 20 elemenata, a iteriranje se može nastaviti naredbom `it`.

Prije primjera za dohvat ćemo učitati tri kolekcije u Mongo **koje će vam trebati i za obavljanje domaćih zadaća**. Preuzmite datoteku `NMBP_datasets.zip` sa stranica predmeta i pratite upute za učitavanje podataka koje se nalaze uz podatke.
U nastavku ćemo koristiti kolekciju cards koja je preuzeta s adrese http://mtgjson.com/.
Format je opisan na http://mtgjson.com/documentation.html.

Dohvat svih elemenata:

```
db.cards.find();
it
```

Upotrijebimo projekciju kako bi pogledali samo name i type polja:

```
db.cards.find({}, {name: 1, type: 1});
```

Očigledno, Mongo vraća i `_id` polje osim ako ga se eksplicitno ne isključi:

```
db.cards.find({}, {_id:0, name: 1, type: 1});
```

`_id` polje je specijalno polje i jedino kod njega je moguće miješati „*include*“ i „*exclude*“ pristup kod projekcije, npr. u gornjem upitu probamo „isključiti“ još i type:

```
db.cards.find({}, {_id:0, name: 1, type: 0});
```

dobiti ćemo pogrešku *BadValue Projection cannot have a mix of inclusion and exclusion*. Moguće je (ako izuzmemo `_id`) ili specificirati atribute koje treba uključiti ili atribute koje ne treba uključiti u rezultat, npr. ako „isključimo“ još i `name`, upit postaje ispravan:

1.2.4 Operatori usporedbe

Za definiranja uvjeta dohvata koristite se operatori usporedbe opisani na stranici:
http://docs.mongodb.org/manual/reference/operator/query-comparison/
Na primjer, dohvatimo sve kartice koje imaju power veći od 4.

```
db.cards.find({power: {$gt: 4}} );
```

Upit ne vraća niti jedan dokument – zašto? Uvjerimo se da polje `power` postoji:

```
db.cards.find({power: { $exists: true }} ).count();
```

U čemu je problem?
Polje `power` nije cjelobrojnog tipa, pa usporedba ne radi dobro.
Pretvorimo `power` u cjelobrojni tip:

```
db.cards.find({power: {$exists: true}}).forEach(function(obj) {
    obj.power = parseInt(obj.power);
    db.cards.save(obj);
});
```

Probajte dohvatiti dokumente koji imaju `power` 99 s funkcijom za „lijepi ispis“:

```
db.cards.find({power: {$eq: 99}} ).pretty()
```

Isprobajmo sada za cjelobrojno polje `cmc` npr. upit koji vraća broj dokumenata koji imaju `cmc > 10`:

```
db.cards.find({cmc: {$gt: 10}}).count();
```

Ili, suprotno (primjer upotrebe negacije):

```
db.cards.find({cmc: {$not: {$gt: 10}}}).count();
```

Dohvatiti karte koje imaju `cmc` jedan ili deset – upotrijebit ćemo `$in` operator (probajte i `$nin`):

```
db.cards.find({cmc: {$in: [1, 10]}}).count();
```

Jednakost i `$in`/`$nin` operator rade i nad poljem. Isprobajte (može i s `$eq`):

```
db.cards.find({subtypes: "Human"} ).pretty()
```

Dohvatite zapise koji imaju ujedno i `Human i Knight subtypes`:

```
db.cards.find({subtypes:{$all: ["Human", "Knight"]}} ).count()
```

Postavimo sada svim zapisima koji imaju `subtype` „`Human`“ dodatni ugniježđeni objekt „`abilities`“ s nekoliko svojstava:

```
db.cards.update(
              { subtypes: "Human" },
              { $set: {
                    abilites: {
                        canFly : "no",
                        canWalk: "yes",
                        canTalk : "yes"
                    }
                }
               }
               , {multi: true}
            );
```

Atributi ugniježđenih objekata se referenciraju dot-notacijom, npr.:

```
db.cards.find( {"abilites.canFly": "no", subtypes : "Wizard"} ).count()
```

Također primijetite da se ovdje koristi AND operator – zarez.
S ugniježđenim dokumentima treba biti oprezan – koliko rezultata vraća naizgled isti upit:

```
db.cards.find( {"abilites" : {canFly: "no"}, subtypes : "Wizard"} ).count()
```

a koliko sljedeća dva:

```
db.cards.find( {"abilites" : {canFly: "no", canWalk: "yes", canTalk : "yes"},
                subtypes : "Wizard"} ).count();

db.cards.find( {"abilites" : {canTalk: "no", canWalk: "yes",  canFly: "yes"},
                subtypes : "Wizard"} ).count();
```

Zašto (sjetite se da Mongo pohranjuje podatke u BSON formatu)?

1.2.5 Operacije nad kursorom

Mongo omogućuje niz operacija nad kursorom http://docs.mongodb.org/manual/reference/method/js-cursor/ , a ovdje ćemo komentirati samo `sort`, `skip` i `limit` koje se često koriste (npr. kod prikaza rezultata upita pomoću više stranica, tzv. *paging*).

Podatke možete sortirati (sortirati se može i pomoću `$orderby query modifiera`) na sljedeći način (silazno po `cmc`, uzlazno po `_id` polju):

```
db.cards.find({subtypes:"Wizard"}, {cmc: 1}).sort( {cmc: -1, _id: 1});
```

te zatim prikazati npr. drugu stranicu veličine 50:

```
db.cards.find({subtypes:"Wizard"}, {cmc: 1}
         ).sort( {cmc: -1, _id: 1}
         ).skip(50
         ).limit(50);
```

1.2.6 Map/Reduce

Mongo ima vrlo kvalitetne mogućnosti agregacije podataka (http://docs.mongodb.org/master/core/aggregation-pipeline/) koja u načelu radi brže od M/R operacija i koje su limitirane jedino raspoloživom paletom operatora/izraza. Naime, neki problemi se možda ne mogu izraziti u toj okolini, dok je M/R pristup „neograničenih“ mogućnosti jer počiva na korisničkim Javascript funkcijama u kojima je moguće obaviti „bilo što“. U realnim uvjetima, prilikom rješavanja konkretnog problema, *aggregation pipeline* bi trebao biti prvi izbor. Budući da se u okviru predmeta proučava načelno M/R algoritam (a Mongo je uzet samo kao jedna od implementacija), ovdje se neće obrađivati *Mongov aggregation pipeline*, već samo M/R.

Karte (ali ne sve!) imaju polje subtypes, npr.:

```
"subtypes" : ["Human", "Wizard"], …
```

Probajmo izračunati koliko ima različitih *subtypeova*, odnosno koliko karata ima koje imaju *subtype Human*, koliko *Wizard*, itd.

Puni oblik map reduce naredbe možete pogledati ovdje: http://docs.mongodb.org/master/reference/command/mapReduce/#dbcmd.mapReduce

Definirajmo prvo map funkciju, koja će za svaku kartu iterirati po polju *subtypes* (ako postoji *subtypes*):

```
var map = function() {
    if (this.subtypes !== undefined)
        this.subtypes.forEach( function(subtype) {
            emit( subtype, 1 );
        }
  );
};
```

Dakle, ovo će za primjer polja gore, emitirati dva zapisa:

```
Human, 1
Wizard, 1
```

U reduce funkciju pristižu svi zapisi grupirani po ključu (to je kod nas *subtype* – *Human, Wizard*, …), te ih je potrebno jednostavno prebrojiti:

```
var reduce = function(key, values) {
    var rv = {
              subtype: key,   // ovaj atrib je zapravo suvišan, jer je isti kako key
              count:0
             };
    values.forEach( function(value) {
        rv.count += value;
    });
    return rv;
};
```

> Mongo ne ispisuje rezultat MR naredbe već statistiku obavljanja. Sam rezultat se mora pohraniti u neku kolekciju koju se poslije može pregledavati. Primijetite da npr. nije moguće u okviru MR naredbe sortirati zapise (odnosno Mongo ih uvijek sam sortira po ključu) već se rezultat spremi u kolekciju, pa se onda naknadno find naredbom mogu sortirati (analogno spremanju u tablicu i onda SELECT ORDER BY u bazama podataka).

Pokrenimo sad M/R, za zadane dvije funkcije i spremimo rezultat u kolekciju mr_cards (ako kolekcija ne postoji Mongo će ju napraviti):

```
db.cards.mapReduce(
                    map,
                    reduce,
                    { out: "mr_cards" }
                  )
```

Te pogledajmo rezultat:

```
db.mr_cards.find()
```

Rezultat nije dobar, zašto, što se dogodilo? Doima se da je umjesto zbrajanja, u nekim slučajevima došlo do konkatenacije?

Probajmo doznati o čemu se radi – smanjiti ćemo ulazni skup, tako da je lakše raditi, dodajemo upit kojim definiramo ulazne podatke za MR – samo one koji imaju (jedan od) *subtypes Antelope*:

```
db.cards.mapReduce(
                    map,
                    reduce,
                    { out: "mr_cards",
                      query: { subtypes: "Antelope" }}
                  );
db.mr_cards.find();
```

Sad su rezultati dobri!?

Doima se da se greška ne događa na manjem skupu?

Dodati ćemo funkcije za ispis u reduce funkciju da vidimo što se zbiva, ali ćemo ispisivati samo za jedan subtype „Whale“, kako bi ispis bio pregledan:

```
var reduce = function(key, values) {
    var rv = {
              subtype: key,
              count:0
             };
    values.forEach( function(value) {
        if (key === 'Whale') print (key + " counting = " + rv.count + " + " + tojson(value));
        rv.count += value;
    });
    if (key === 'Whale') print ("reduce for " + key + " returning " + rv.count);
    return rv;
};
```

Ponovo pokrenite M/R za sve zapise i gledajte ispis (pogledajte komentar za print na početku dokumenta kako bi znali gdje pronaći ispis). Sada se vidi da za *Whale* jedno vrijeme radi dobro, a onda umjesto broja 1 u polju se pojavljuje objekt? Zaključite o čemu se radi, pogledajte u predavanjima temu *combinable reducer* i pogledajte dokumentaciju Monga za reduce funkciju: http://docs.mongodb.org/master/reference/command/mapReduce/#mapreduce-reduce-cmd

Prepravimo map i reduce funkcije:

```
var map = function() {
    if (this.subtypes !== undefined)
        this.subtypes.forEach( function(subtype) {
            emit( subtype, {subtype: subtype, count : 1} );
        }
  );
};

var reduce = function(key, values) {
    var rv = {
              subtype: key,
              count:0
             };
    values.forEach( function(value) {
        rv.count += value.count;
    });
    return rv;
};
```

Te ponovo pokrenite M/R. Koliko vremena je trebalo za izračun?
Primijetite da mongo omogućuje i `finalize` funkciju kojom je moguće dodatno obraditi rezultate reduce faze, npr. promijenimo malo format rezultata:

```
var fin = function (key, reducedVal) {
   return {count : reducedVal.count};
};

db.cards.mapReduce(
                    map,
                    reduce,
                    { out: "mr_cards",
                      finalize : fin
                    }
                  )
```

Ovime su pokazane osnovne M/R funkcionalnosti, kao i osnovni pristup pri uklanjanju pogrešaka.
Više o svemu možete naći na službenoj web stranici: http://docs.mongodb.org/master/tutorial/map-reduce-examples/
Uočite da mongo ima i inkrementalni M/R (neće se ispitivati).

1.2.7 Indeksi

Pročitajte uvodno objašnjenje o indeksima na stranici: http://docs.mongodb.org/master/core/indexes-introduction/
Odgovorite na sljedeća pitanja:

- Zašto nastankom prve kolekcije u bazi odmah nastaje i `system.indexes` kolekcija? Pogledajte njen sadržaj.
- Koje vrste indeksa mongo podržava?
- Zašto `hashed index` ne može odgovoriti na `range queries`? Koja svojstva može posjedovati indeks?

Pogledajmo i usporedimo planove obavljanja upita za dva različita atributa naše kolekcije:

```
db.cards.find({_id: "Black Knight"}).explain();
db.cards.find({cmc: 3}).explain();
```

Napravimo sad i indeks na cmc atributu, pa ponovo pogledajmo system.indexes i plan obavljanja:

```
db.cards.createIndex({cmc : 1})
db.system.indexes.find()
db.cards.find({cmc: 3}).explain();
```

Za vježbu još napravite i *multikey index* i *text index* na odgovarajućim poljima.

1.2.8 Binarne datoteke

Binarne datoteke (npr. slike) se također mogu pohraniti u mongo (koristeći BSON BinData tip podataka), ali uz ograničenje da ne smiju biti veće od 16MB.
Ako su vaše datoteke potencijalno veće od 16MB, moguće je koristiti GridFs:
http://docs.mongodb.org/manual/faq/developers/#faq-developers-when-to-use-gridfs

Naravno, možete ga koristiti i kad nisu veće od toga.

Datoteku s diska možete učitati u GridFs koristeći *mongofiles* utility, npr.:

```
mongofiles --host 192.168.56.12 --db nmbp put -l "D:\put_do_datoteke\slika.jpg" slika.jpg
```

http://docs.mongodb.org/manual/reference/program/mongofiles/

Napomena: Konfiguracija replikacije i fragmentacije prikazana u nastavku je prikladna samo za potrebe testiranja i razumijevanja koncepata, nikako za produkcijske servere!

Napomena: Ove teme su obrađene tek u četvrom NoSQL predavanju, tako da ih možete isprobati nakon tog predavanja. Naredbe su u Linux formatu, tako da će za Windowse možda biti potrebno blago promijeniti sintaksu.

1.3 Replikacija

Pročitajte stranicu s osnovama replikacije: http://docs.mongodb.org/master/core/replication-introduction/

Isprobati ćemo napraviti `replica set` od tri čvora, operacije čitanja i pisanja, te uzrokovati izbore novog `primary` čvora.

Napravite tri nova direktorija u kojima će tri instance monga čuvati svoje podatke:

```
mkdir -p /usr/mongo/rs0-0 /usr/mongo/rs0-1 /usr/mongo/rs0-2
```

pokrenite tri nova terminala (onu standalone instancu iz prethodnih vježbi čak možete ostaviti da radi, side-by-side, s našim novim replica setom), prijavite se i u svakom pokrenite odgovarajuću naredbu (format naredbe odgovara linux sustavima, prilagodite za Windowse ako ih koristite, na početku dokumenta imate primjer kako se zadaje `dbpath` u Windowsima):

```
mongod --port 27018 --dbpath /usr/mongo/rs0-0 --replSet rs0 --smallfiles --oplogSize 128
mongod --port 27019 --dbpath /usr/mongo/rs0-1 --replSet rs0 --smallfiles --oplogSize 128
mongod --port 27020 --dbpath /usr/mongo/rs0-2 --replSet rs0 --smallfiles --oplogSize 128
```

Sada su pokrenute tri instance, svaka s vlastitim direktorijem za pohranu podataka, ali nisu još umreženi odnosno nije još inicijaliziran replica set.
Pokrenite četvrti ☺ terminal, te se spojite iz shella na jedan od novih čvorova:

```
mongo --port 27018
```

te konfigurirajte replica set (prilagodite IP adresu ako je potrebno):

```
rsconf = {
          _id: "rs0",
          members: [
                    {
                     _id: 0,
                     host: "127.0.0.1:27018"
                    }
                   ]
        }
rs.initiate( rsconf )
rs.conf()
```

Konačno, dodajte preostale dvije instance u `replica set` (prilagodite IP adresu ako je potrebno). Dodavanjem se izabire `primary` čvor, primijetite kako vam se mijenja prompt u shellu:

```
rs.add("127.0.0.1:27019")
rs.add("127.0.0.1:27020")
```

Probajte:

```
rs.conf();
rs.status();
```

Spojite se na PRIMARY (ako već niste) i snimite jedan zapis u defaultnoj test bazi podataka:

```
db.test.save({opis: "prvi"});
```

Izađite iz shella i spojite se na jedan od SECONDARY čvorova i probajte:

```
mongo --port 27019
db.test.save({opis: "drugi"})
show collections
show dbs
```

Ništa ne radi. Postavite da je za tekuću konekciju dozvoljeno čitati s SECONDARY čvora:

```
rs.slaveOk()
```

i probajte ponovo sve te naredbe (kako biste to napravili iz npr. web aplikacije?).
Izađite iz shella i spojite se na PRIMARY. Naredite mu da odstupi:

```
rs.stepDown()
```

i gledajte što se događa u terminalima ostala dva SECONDARY čvora – oni organiziraju izbore!
Prethodni PRIMARY je i dalje aktivan u `replica setu`, samo je sada SECONDARY.

Doznajte koji je novi PRIMARY i spojite se na njega. Ugasite ga:

```
use admin
db.shutdownServer()
```

Spojite se na neki od preostalih čvorova i pogledajte stanje:

```
rs.status();
```

Na isti način ugasite preostali PRIMARY i pogledajte što se dogodilo.

1.4 Fragmentacija (eng. *sharding*)

Pročitajte uvodni tekst na: http://docs.mongodb.org/master/core/sharding-introduction/

Nastavak je opcionalan, ne morate ga znati reproducirati u okviru predmeta. Slijedi niz naredbi kojima će se uspostaviti testni *sharding cluster* s :

- jednim *config* serverom,
- jednim *routing* serverom i
- dva *shard* servera.

Ugasite sve servere iz prethodnih vježbi. Otvorite novi, prvi terminal.

Napravimo direktorij za *config* server

```
mkdir -p /usr/mongo/configdb
```

i pokrenimo ga (na portu 27019):

```
mongod --configsvr --dbpath /usr/mongo/configdb --port 27019
```

Otvorite drugi terminal te pokrenite *router (mongos).* Kao argument predajmo adresu *config* servera:

```
mongos --configdb 127.0.0.1:27019
```

Mongos ne treba podatkovni direktorij i sluša na defaultnom portu 27017.

Otvorite nova dva terminala. Napravimo nove podatkovne direktorije za dva shard servera:

```
mkdir -p /usr/mongo/sh1 /usr/mongo/sh2
```

i pokrenimo ih:

```
mongod --port 27020 --dbpath /usr/mongo/sh1 --smallfiles --oplogSize 128
mongod --port 27021 --dbpath /usr/mongo/sh2 --smallfiles --oplogSize 128
```

Pokrenite peti terminal ☺, te se spojite sa *shellom* na *routing server*:

```
mongo --host 127.0.0.1 --port 27017
```

Konačno, dodajmo naša dva *sharding servera*:

```
sh.addShard( "127.0.0.1:27020")
sh.addShard( "127.0.0.1:27021")
```

provjerimo status:

```
sh.status();
```

Trenutno se još uvijek ništa ne fragmentira. Omogućimo fragmentaciju na bazi shtest:

```
use shtest;
sh.enableSharding("shtest");
```

te omogućimo i definirajmo fragmentaciju na kolekciji cards (zasad nepostojećoj)
na temelju atributa _id:

```
sh.shardCollection("shtest.cards", { "_id": "hashed" } )
```

Ponovite postupak kojim se karte iz datoteke AllCards.json učitavaju u bazu, te pogledajte kako su distribuirani podatci:

```
db.cards.getShardDistribution()
sh.status();
```

2 Projektni zadatak

Potrebno je napraviti dva zadatka opisana u nastavku.

2.1 NoSQL1: Minimalni portal temeljen na MongoDB (10 bodova)

Napraviti web portal koji ispisuje najnovijih N (npr. N=10) vijesti.

> **?** Osmisliti kako, odnosno upotrijebiti prikladnu strukturu podataka za to.
> Na primjer, ako pretpostavimo da u bazi imamo 100.000 članaka, **nije dobra** strategija dohvatiti svih 100.000 zapisa na klijenta, sortirati i uzeti prvih deset.

Svaka vijest treba biti (otprilike) sljedećeg oblika:

<table>
<tr><td>Naslov</td><td rowspan="3">Slika</td></tr>
<tr><td>Tekst</td></tr>
<tr><td>Autor</td></tr>
</table>

Omogućiti komentiranje vijesti: ispod svake vijesti dodati polje za unos komentara.
Nije potrebno napraviti sučelje za unos vijesti, odnosno možete ih sve unijeti ručno.

U bazi treba biti barem 10.000 vijesti. Možete ih generirati ili skinuti neki skup podataka s Interneta, ali svakako trebate (strojno) napuniti barem 10 tisuća vijesti.

Npr.:

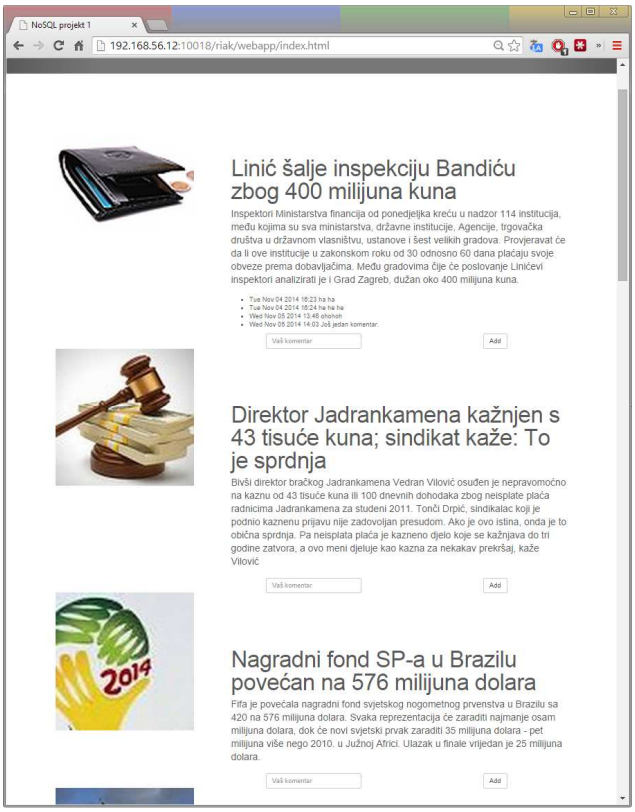

2.2 NoSQL2: MapReduce upit (2 + 2 + 6 = 10 bodova)

Napisati:

(a) (2 boda) MapReduce upit koji vraća broj članaka po broju komentara.
Npr.

```
10: 172 // 172 članka s 10 komentara
9: 312   // ...
…
0: 1234  // 1234 članka s nula komentara
```

(b) (2 boda) MapReduce upit postotak komentiranih članaka (nije bitno koliko komentara imaju, već samo imaju li ili nemaju).
Npr.

```
0.12    // 12% članaka je bar jednom komentirano, 88% članaka ima 0 komentara
```

(c) (6 bodova) MapReduce upit koji za svakog autora vraća prvih 10 najkorištenijih riječi.
Pojam „riječ“ shvatiti u najjednostavnijem mogućem obliku (niz slova odvojen od drugih s razmakom, zarezom ili točkom).
Nije potrebno raditi nikakve leksičke transformacije na riječima (svođene na korijen i sl.).
Nije potrebno ispisati i 11. riječ ako se ima isti broj korištenja kao 10. riječ.

Priznavati će se (sa smanjenim bodovima) i polovična rješenja, npr. sve riječi koje je autor koristio (a ne prvih 10) i sl.

Za sve zadatke:

Možete koristiti proizvoljnu tehnologiju, postoji velik broj drivera za MongoDB:
http://docs.mongodb.org/ecosystem/drivers/

Zadatci će se predavati osobno, tj. potrebno je demonstrirati rješenje.

Razmatrati će se i polovična rješenja (npr. samo prvi zadatak, bez komentiranja vijesti).

Rješenja projekta trebaju sadržavati readme.txt dokument u korijenskom direktoriju u kojoj se objašnjava:

- Kako je riješen zadatak (koja tehnologija, kako su uneseni test podatci, itd.)
- Kako pokrenuti rješenje

Studente se kod predavanja može pitati da:

- objasne nešto iz rješenja (main.txt)
- objasne neki koncept iz Uputa (npr. *replica set*)
- pokrenu tj. demonstriraju rješenje (i npr. dodaju vijest na portal)
- naprave neke manje modifikacije (npr. blago modificirati M/R upit)
- itd.